MELOWAVE · ÉTUDES MUSICALES

Analyser et anticiper les tendances du streaming

Ce qui rend un morceau populaire aujourd'hui, et la place de la pop dans les six prochains mois.

Bader B.
Data Analyst

Camille Roussel
Directrice des études musicales

Octobre 2026
Soutenance du projet

2

questions posées par Camille pour conseiller les labels

MeloWave · distributeur musical indépendant

Des recommandations aux labels fondées sur les données, pas sur l'intuition

MISSION 1 · PHOTOGRAPHIER

Qu'est-ce qui rend un morceau populaire aujourd'hui ?

Analyse du catalogue : profils audio, genres, artistes, et trois questions du comité vérifiées par des **tests statistiques**.

MISSION 2 · ANTICIPER

La pop va-t-elle monter ou descendre dans six mois ?

Suivi de la pop dans le **Top 200 mondial** de 2017 à 2020 et **prévision** avec le modèle Prophet.

Objectif final : un **calendrier de sorties plus précis**, et savoir quels genres pousser, où et quand.

3

messages à retenir, détaillés dans la suite de la présentation

Ce que les labels doivent retenir

01

Le genre fait la popularité, pas le son

Le genre explique **27 %** de la popularité d'un morceau ; aucune caractéristique audio n'en explique plus de **2 %**.

02

La pop recule, mais Noël reste son temps fort

De **94 à 74 places** du Top 200 mondial entre 2017 et 2020, un recul retrouvé dans **32 marchés sur 35**. Chaque décembre, elle regagne 26 à 32 places.

03

La prévision sert à planifier, pas à chiffrer

Fiable pour le **calendrier** et les saisons, elle ne voit pas les **retournements** de tendance.

Les preuves suivent, slides 5 à 16

9,8 M

millions de lignes de classements quotidiens, 35 marchés, 2017 à 2020

- Catalogue : **114 000** lignes, **89 740** morceaux distincts, 114 genres
- Sorties : **51 754** morceaux datés

Des données vérifiées avant d'être analysées

MISSION 1 · CATALOGUE

Audit, description, tests

1 ligne incomplète et **450 doublons stricts** retirés. Base principale : **113 549 lignes**, une par morceau et par genre, comme le corrigé. Les **89 740 morceaux distincts** servent aux classements d'artistes et aux analyses complémentaires.

MISSION 2 · CLASSEMENTS

Série, prévision, évaluation

Série quotidienne de la pop dans le Top 200 mondial, **5 jours de collecte manquants** repérés et traités. Prophet entraîné puis testé sur les **90 derniers jours**, jamais vus par le modèle.

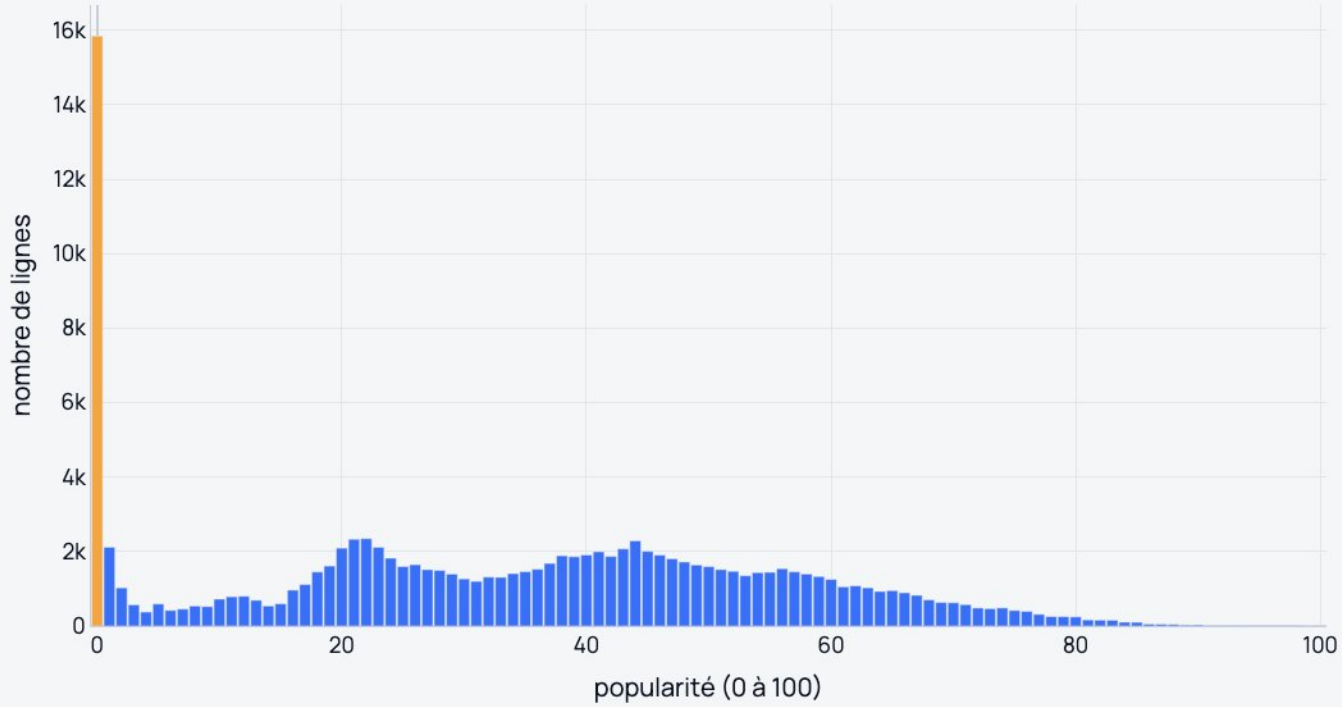
Outils : Python, pandas, SciPy, Prophet, Plotly. Notebooks paramétrés : genre et marché se changent en une ligne.

14 %

des lignes du catalogue ont une popularité nulle

- Popularité médiane : **35 sur 100**, moyenne 33,3
- Seulement **4,8 %** des lignes dépassent 70
- Base principale : **113 549 lignes**, une par morceau et par genre, comme le corrigé

Un catalogue de niche : peu de titres très écoutés, beaucoup de titres confidentiels



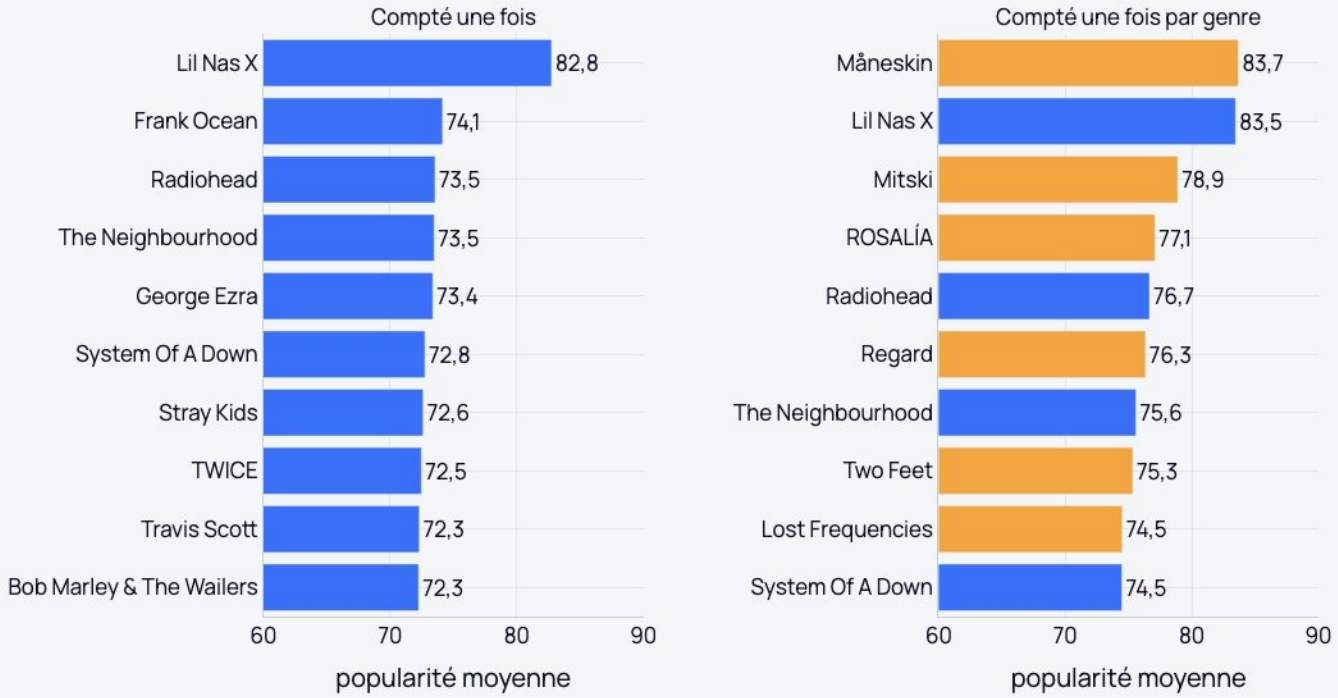
Répartition des 113 549 lignes selon la popularité. En orange : popularité nulle.

9 / 15

artistes du top passent le seuil de 8 morceaux grâce aux doublons, si un morceau compte une fois par genre

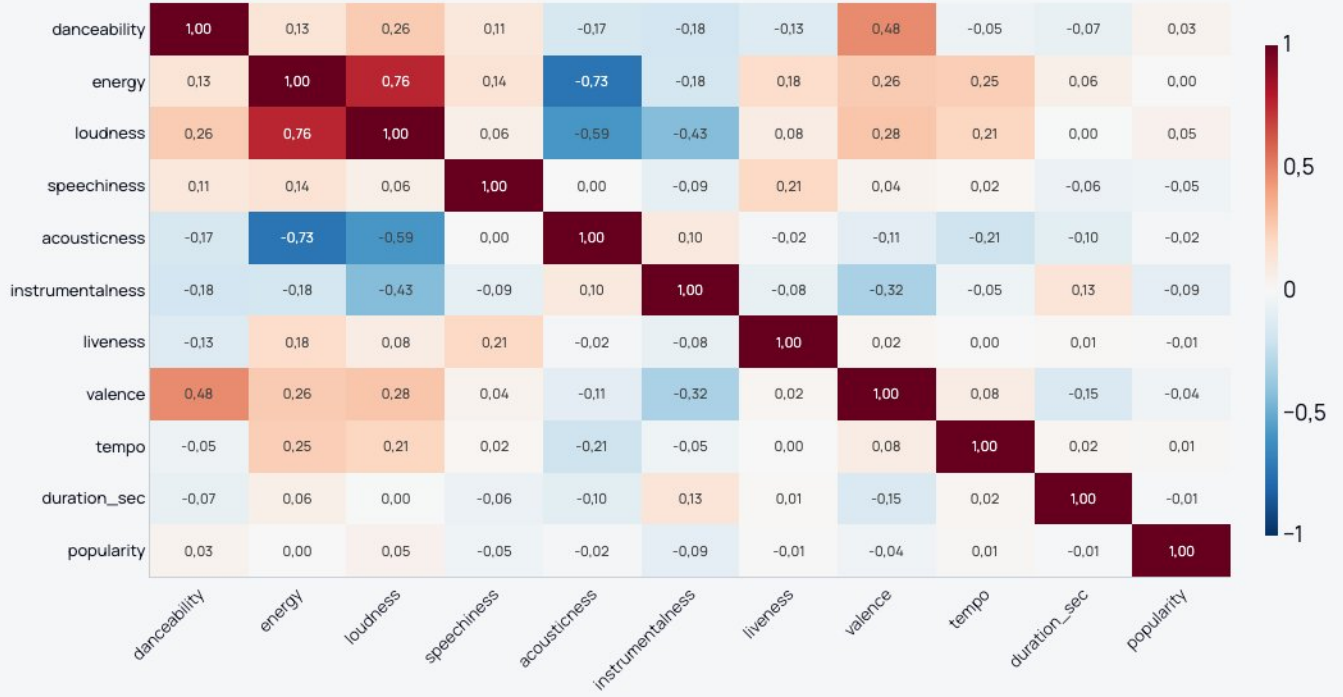
- Morceau compté une fois : **Lil Nas X** en tête (82,8 sur 100)
- Une fois par genre : **Måneskin** en tête avec 12 lignes, pour **5 morceaux réels** (en orange : moins de 8 morceaux réels)
- Seuls **6 artistes** sur 15 sont communs aux deux classements
- Les plus gros catalogues (George Jones, 332 morceaux) ne sont pas les plus populaires

Pour classer les artistes, chaque morceau ne doit compter qu'une fois



Popularité moyenne des 10 premiers artistes (minimum 8 morceaux). À gauche : morceaux distincts. À droite : une ligne par morceau et par genre, comme dans la base principale.

Matrice de corrélation des variables audio et de la popularité



Coefficients de Pearson sur la base principale (113 549 lignes). Rouge : lien positif ; bleu : lien négatif.

11

variables croisées dans la matrice de corrélation, popularité comprise

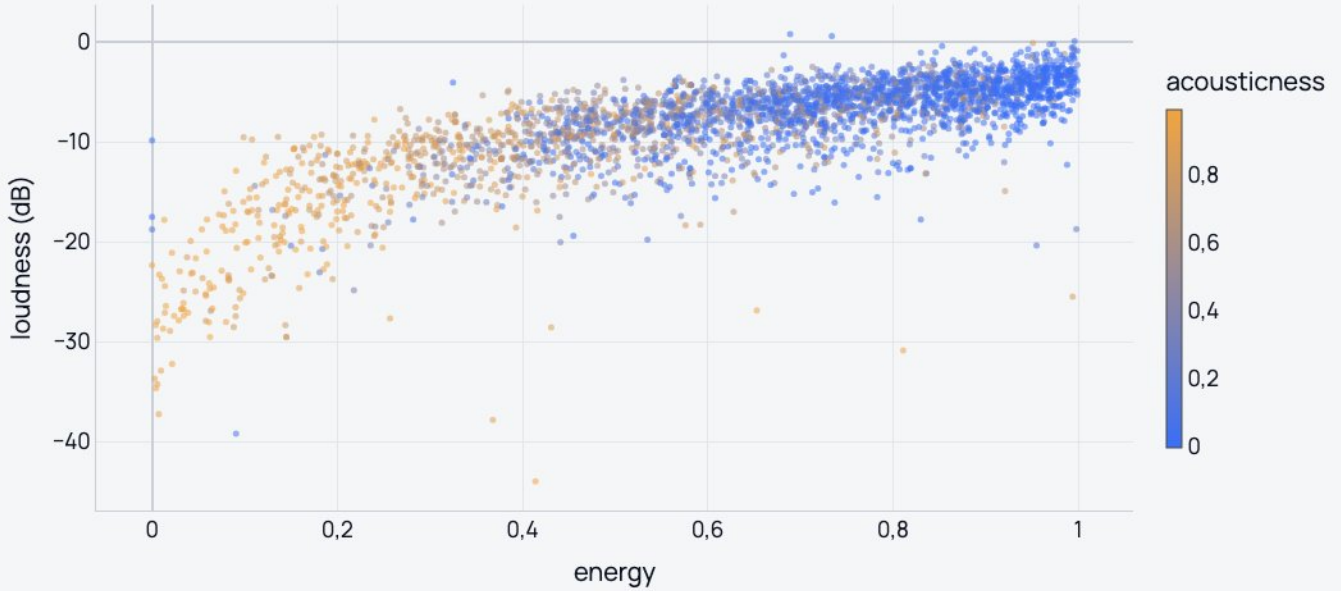
- Liens forts : energy et loudness (**0,76**), acousticness et energy (**-0,73**)
- Popularité : aucune corrélation au-delà de **0,1** en valeur absolue

0,75

corrélation entre energy et loudness : une relation forte

- **Test : Spearman**, car les variables ne suivent pas une loi normale (Shapiro-Wilk)
- Acousticness et energy : **-0,71**, relation inverse forte
- p-value (probabilité que le résultat soit dû au hasard) < 0,001 dans les deux cas

Energy, loudness et acousticness décrivent la même chose



Pour Camille : energy, loudness et acousticness mesurent presque la même chose. Pour décrire un morceau, en suivre une seule suffit ; danceability, valence ou speechiness apportent davantage d'information nouvelle.

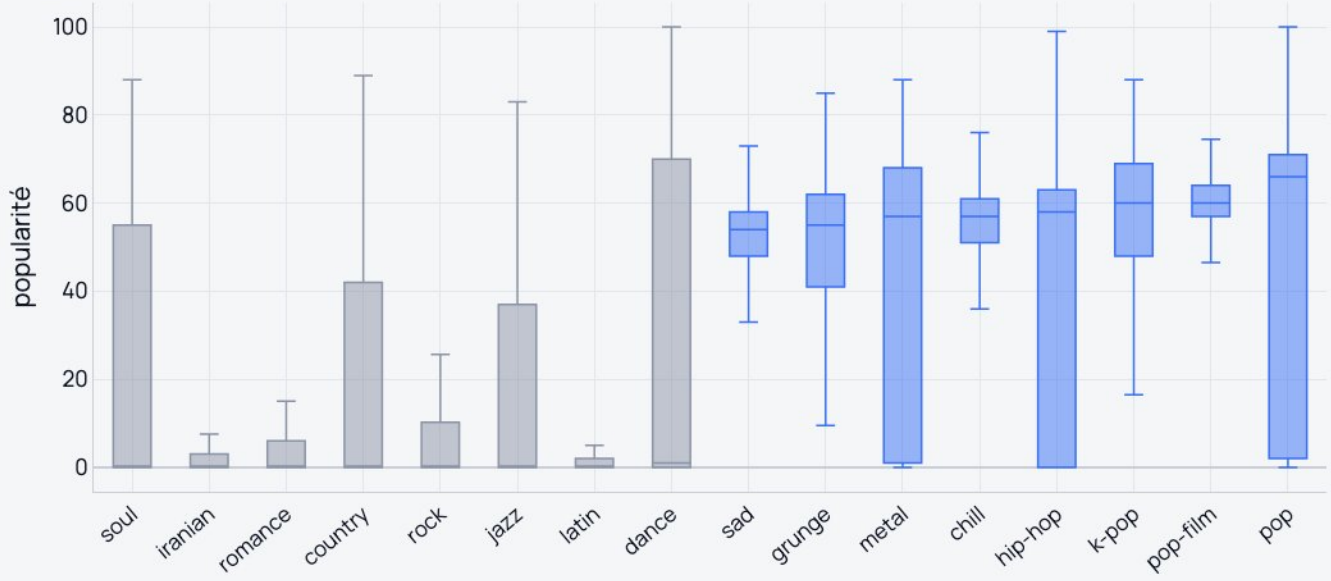
3 000 morceaux tirés au hasard. Couleur : acousticness. Musique produite et forte en haut à droite, acoustique et calme en bas à gauche.

27 %

de la popularité d'un morceau expliquée par son genre

- **Test : Kruskal-Wallis**, car la popularité n'est normale dans aucun genre (Shapiro-Wilk par genre)
- H (statistique du test) = 30 955, p-value (probabilité que le résultat soit dû au hasard) < 0,001 ; l'ANOVA (analyse de la variance) confirme
- Taille d'effet **ε² (epsilon carré) = 0,27** : effet fort

Le genre explique 27 % de la popularité d'un morceau



Pour Camille : le genre pèse réellement sur le succès d'un titre. Certains genres sont « à hits », très dispersés, où quelques titres portent tout le genre (pop, hip-hop) ; d'autres sont plus réguliers (chill, pop-film). Le genre est donc un vrai levier de décision.

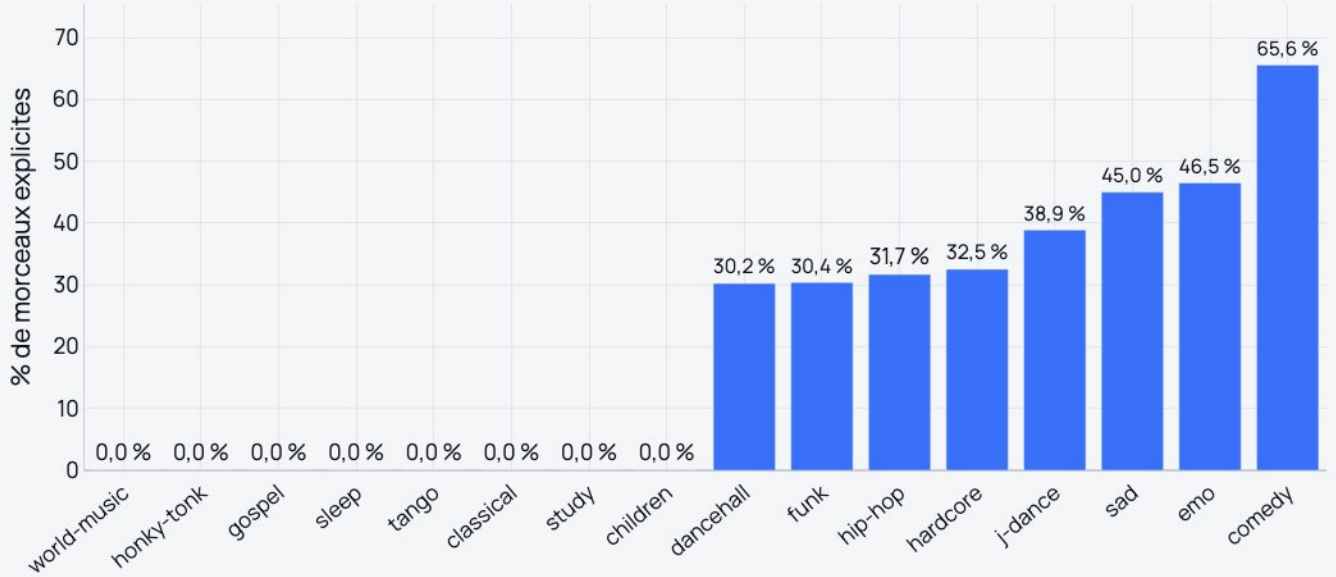
Les 8 genres les moins populaires (gris) et les 8 plus populaires (bleu), classés par popularité médiane.

0,40

V de Cramér : une association marquée entre genre et contenu explicite

- **Test : khi²**, deux variables qualitatives (genre, explicite oui ou non)
- khi² = 18 362, 113 degrés de liberté, p-value (probabilité que le résultat soit dû au hasard) < 0,001
- De **0 %** de titres explicites (world-music) à **65,6 %** (comedy)

Le contenu explicite dépend fortement du genre



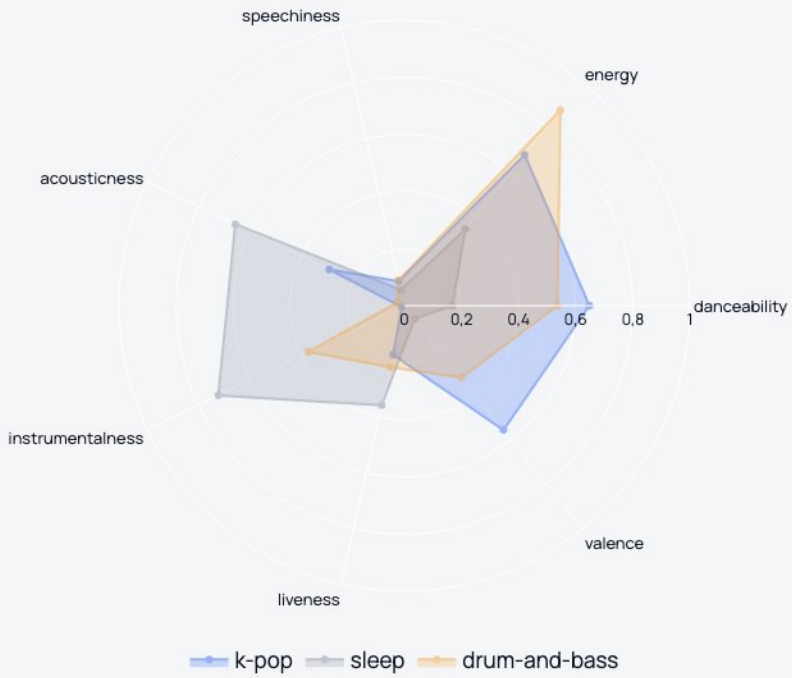
Pour Camille : selon le genre, de 0 % à 66 % des titres sont explicites. C'est un critère à intégrer pour cibler le public (playlists familiales, radio) et calibrer la modération des recommandations.

Part de morceaux explicites : les 8 genres les moins et les 8 plus explicites.

Trois genres, trois profils sonores bien distincts

0,72

instrumentalness moyenne du sleep, contre 0,37 pour le drum-and-bass et 0,01 pour la k-pop



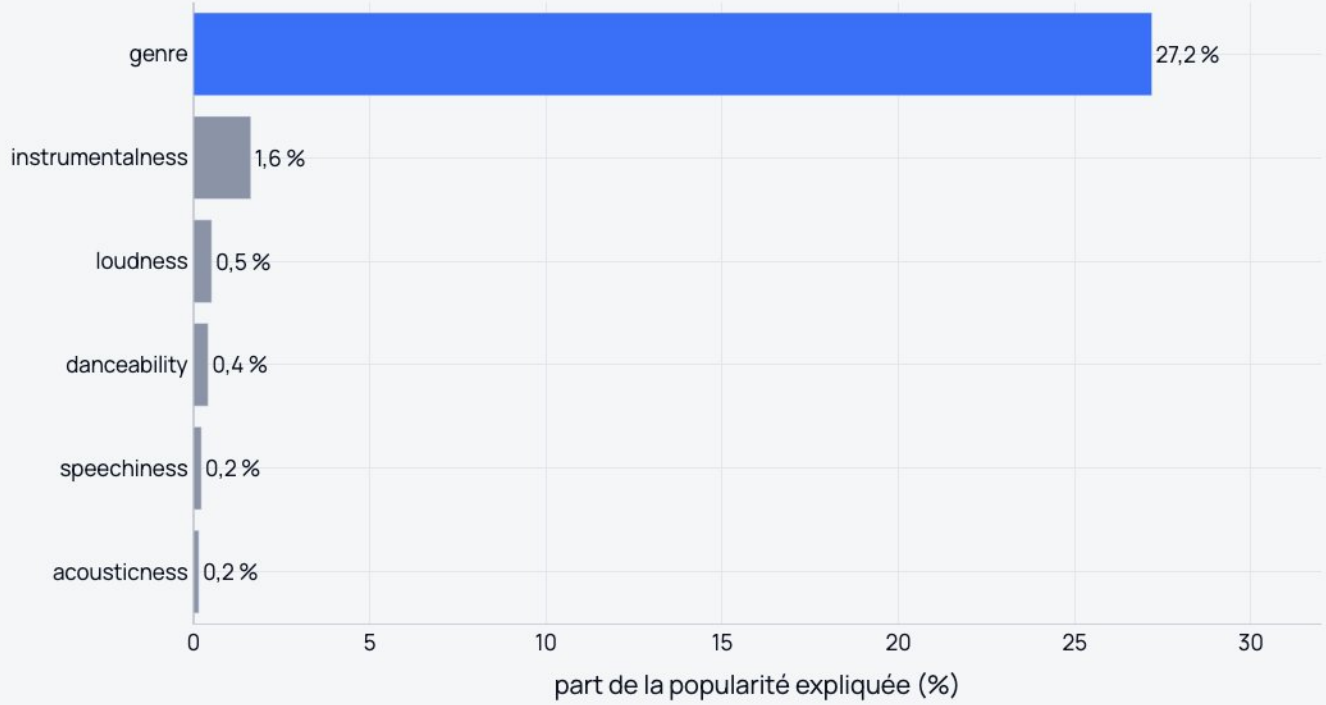
Moyenne des variables comprises entre 0 et 1, base principale. La présence ou l'absence de voix (instrumentalness) sépare le mieux les genres.

- **Sleep** : acoustique, sans voix, peu énergique
- **Drum-and-bass** : énergie maximale (0,88), production électronique
- **K-pop** : la plus dansante et la plus positive, chantée

Le profil sonore n'explique pas la popularité, le genre si

×17

le genre pèse 17 fois plus que la meilleure variable audio



Part de la popularité expliquée : ε² (epsilon carré, taille d'effet) pour le genre, r² (carré du coefficient de corrélation) pour les 5 variables audio les plus liées (morceaux distincts).

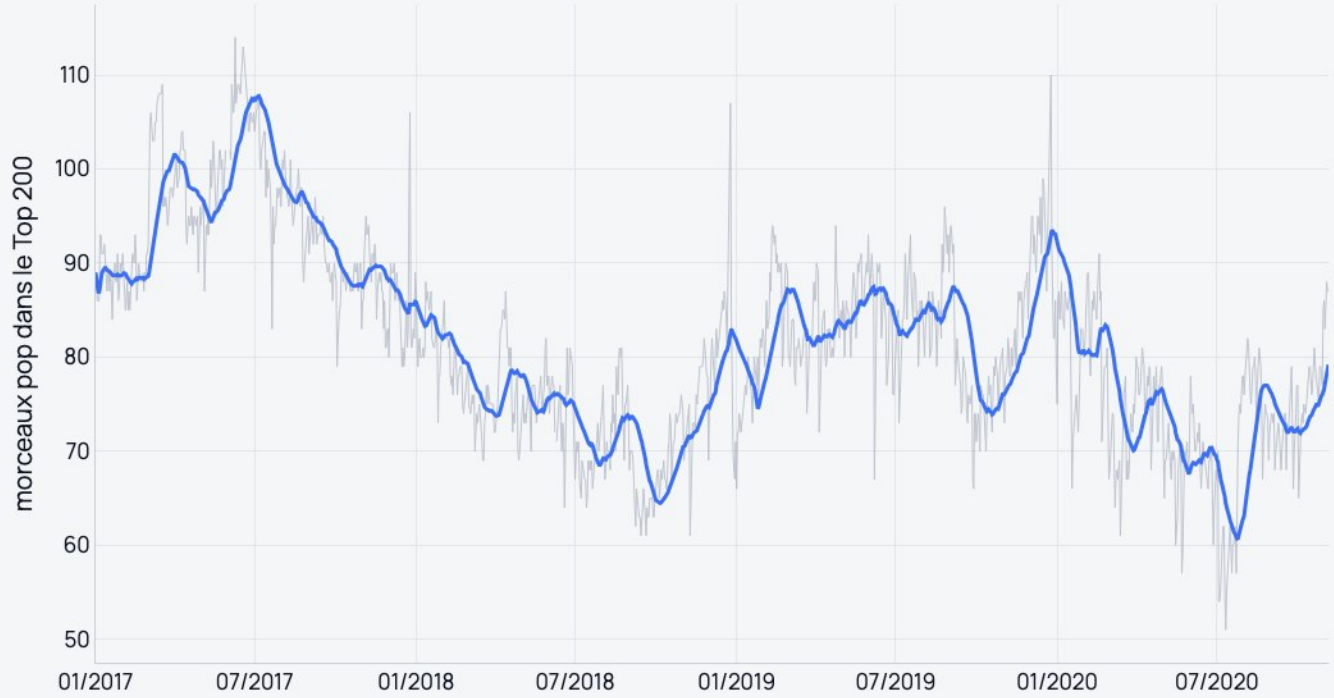
- Meilleure variable audio : **instrumentalness**, avec r (coefficient de corrélation) = -0,13 ; absente de la demande initiale
- Le son ne fait pas le succès ; le genre, l'artiste et la promotion, si
- **D'où la Mission 2** : suivre un genre dans le temps

94 → 74

places moyennes de la pop dans le Top 200 mondial, de 2017 à 2020

- Chaque décembre : **+26 à +32 places**, portées par les titres de Noël
- Point bas : **61 places** le 23 juillet 2020
- Fin de série en reprise : **79 places** début novembre 2020

La pop recule dans le Top 200 mondial, sauf à Noël

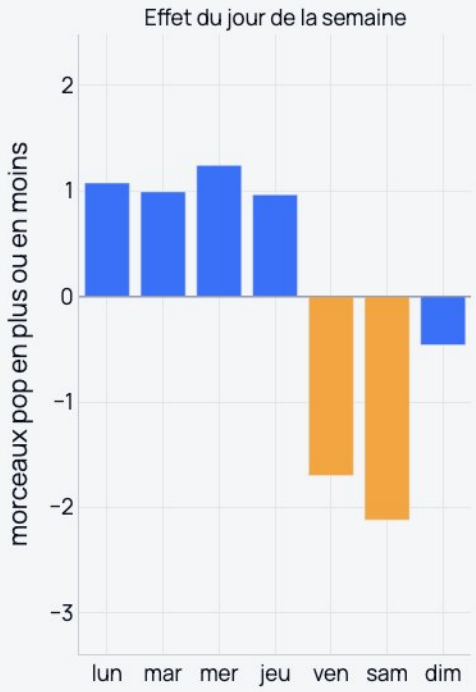


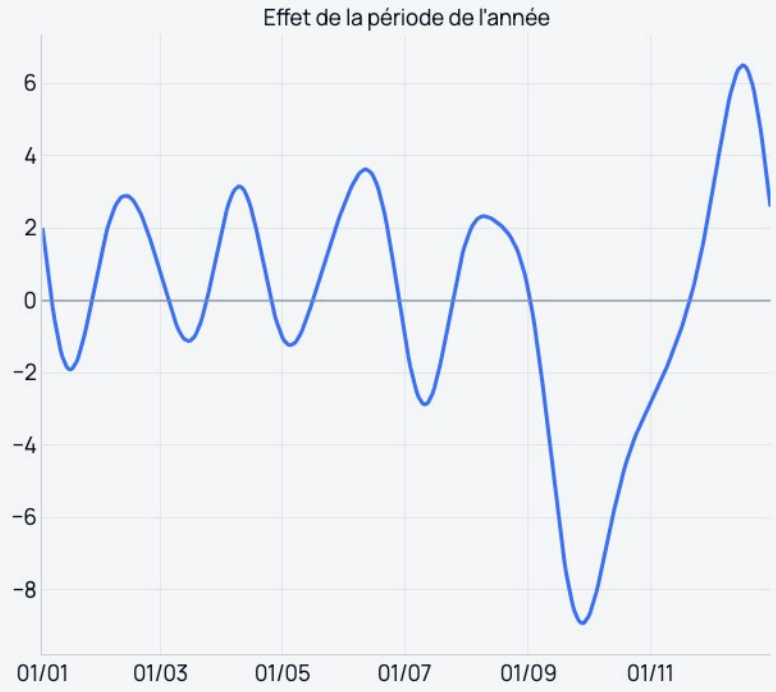
Nombre de morceaux pop dans le Top 200 mondial, chaque jour (gris) et en moyenne mobile sur 30 jours (bleu).

La pop a ses rythmes : Noël en haut, la rentrée et le week-end en bas

17/12

pic annuel de la pop, porté par les titres de Noël





Composantes saisonnières estimées par Prophet (effet annuel montré sur 2019). Jours de sortie en orange.

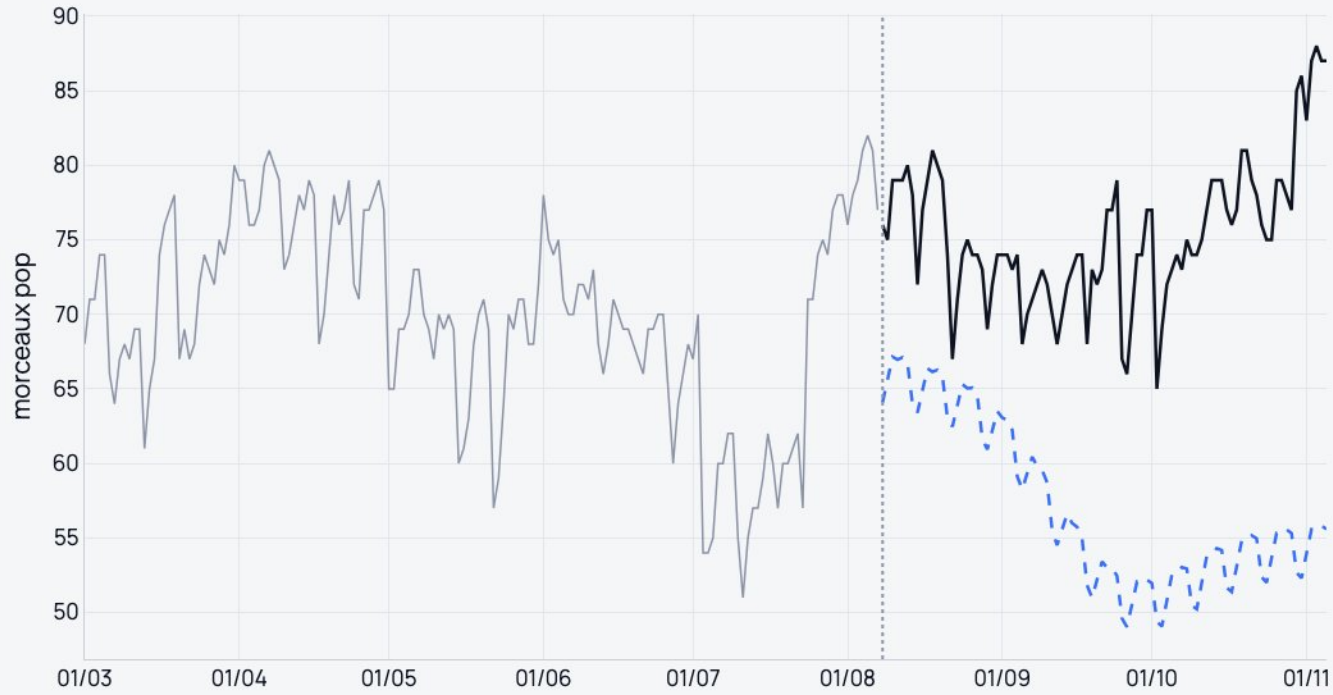
- Creux autour du **28 septembre** (-8,9 morceaux) : la rentrée profite au rap et au latin
- Vendredi **-1,7**, samedi **-2,1** : le jour des sorties, les nouveautés des autres genres repoussent la pop
- Le hip hop gagne **3,3 places** le vendredi

24 %

d'erreur : MAPE (erreur moyenne en pourcentage) sur les 90 jours de test

- MAE (erreur absolue moyenne) **18,3** morceaux par jour, RMSE (racine de l'erreur quadratique moyenne) **19,6**
- **90 jours sur 90 sous-estimés** : une erreur systématique, pas du hasard
- Le modèle prolonge la baisse, alors que la pop repart dès le 23 juillet

Le modèle retrouve le rythme, mais rate les retournements



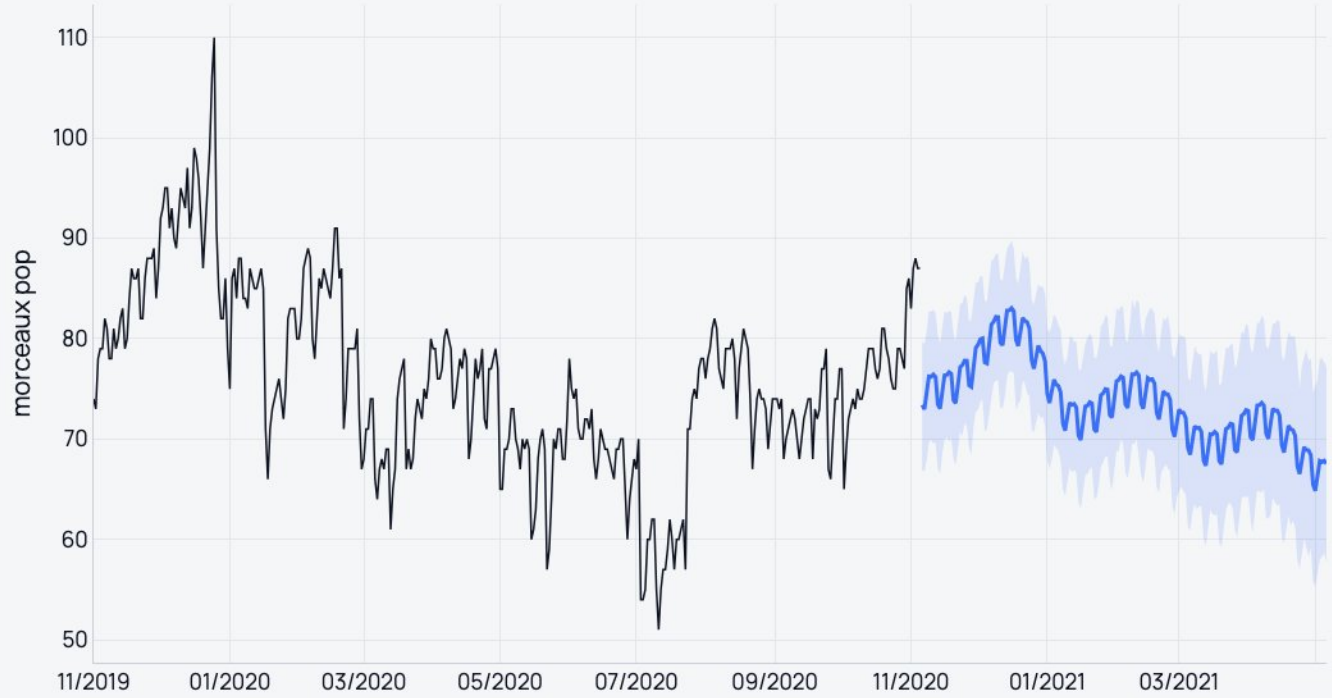
Réel (noir) contre prévu (bleu pointillé) sur la période de test, du 8 août au 5 novembre 2020.

74

places en moyenne prévues pour la pop,
de novembre 2020 à mai 2021

- Pic de Noël : **78 places**, puis lent recul jusqu'à 67 en mai
- Départ **probablement trop bas** : 75 prévus contre 86 réels
- Incertitude croissante : intervalle de **12,7** à **18,5** morceaux

Dans six mois : environ 74 places, avec un pic à Noël



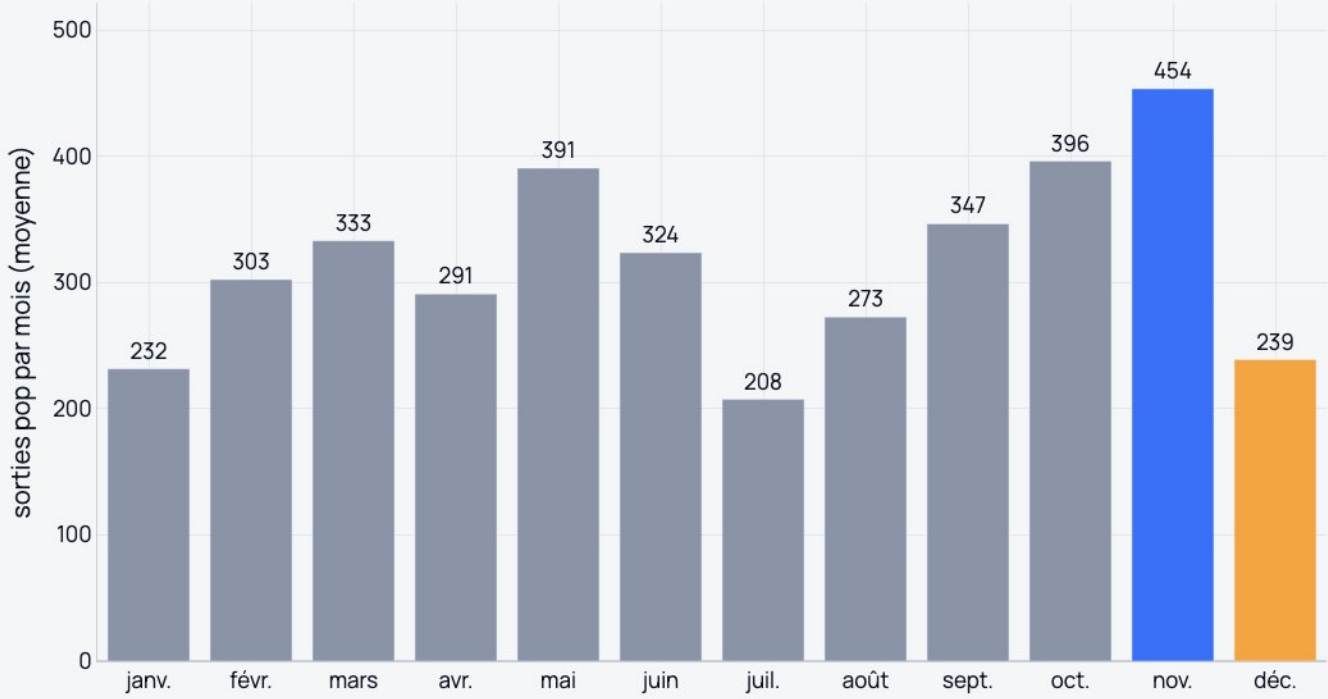
Réel depuis novembre 2019 (noir), prévision (bleu) et intervalle de confiance à 80 %.

454

sorties pop en moyenne en novembre, contre 239 en décembre

- Décembre : peu de nouveautés, mais le plus de pop classée : le pic de Noël vient des **classiques**
- Prévision des sorties : MAPE (erreur moyenne en pourcentage) **21 %**, 4 mois sur 6 à 14 sorties près
- Octobre 2020 sous-estimé d'environ 10 % (collecte arrêtée, annexe A4)

Les labels sortent leur pop en novembre, pas en décembre



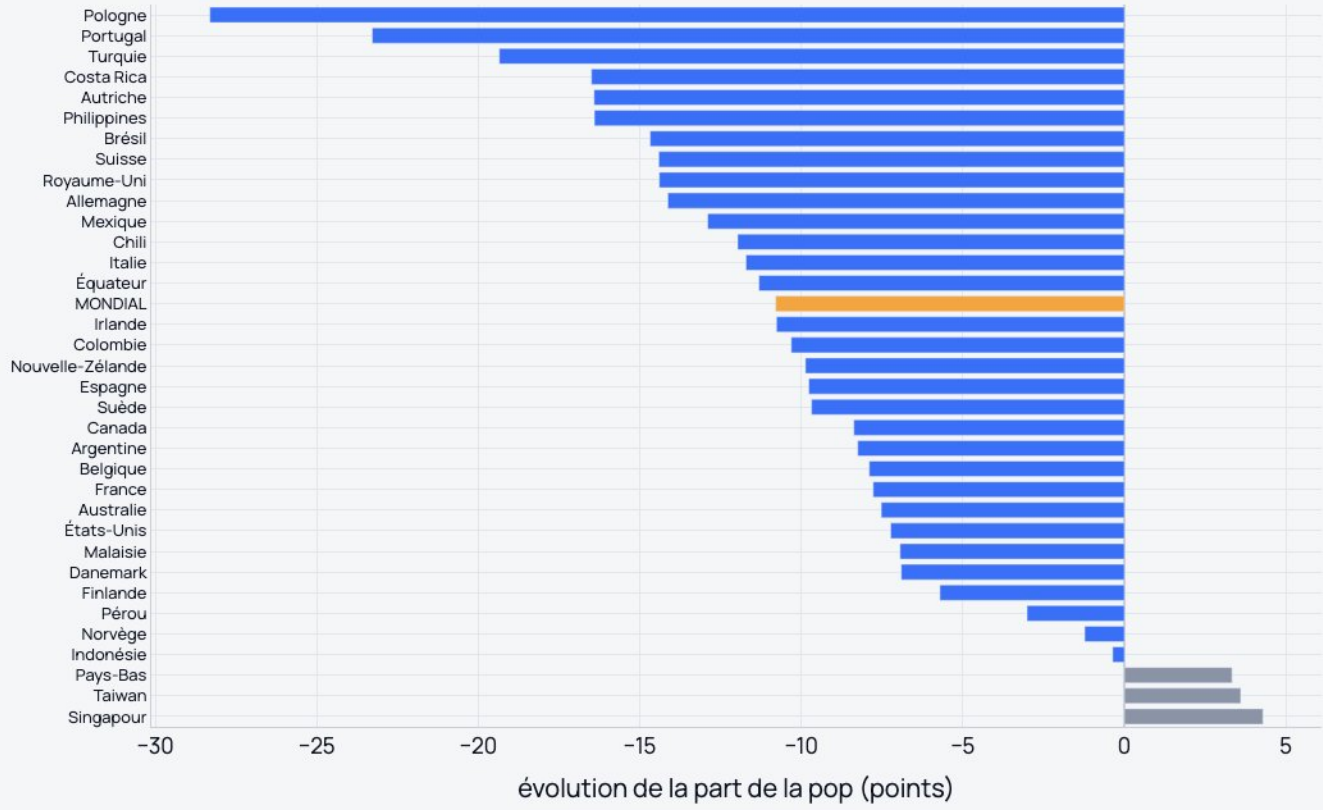
Moyenne mensuelle des sorties pop entrées dans les classements, 2017 à 2020.

32 / 35

marchés où la part de la pop recule
entre 2017 et 2020

- Dans **16 marchés**, la pop n'est plus le premier genre : latin, hip hop, rap
- Points forts : **Asie du Sud-Est** et **Nord de l'Europe**
- Vigilance : en France, l'étiquette « indie » regroupe des **rappeurs**

Le recul de la pop se retrouve presque partout



Évolution de la part de la pop, janvier à octobre 2017 contre 2020. Classement mondial en orange.

2

questions posées par Camille, deux réponses appuyées par les données

Le genre fait le succès ; la pop recule, mais garde Noël

QUESTION 1 · AUJOURD'HUI

Qu'est-ce qui rend un morceau populaire ?

Son **genre**, qui explique 27 % de sa popularité. Le profil sonore en explique moins de 2 % : il décrit la musique, il ne prédit pas le succès.

QUESTION 2 · DANS SIX MOIS

Où va la pop ?

Environ **74 places** du Top 200 mondial, avec un pic à Noël. Une tendance au recul, partagée par 32 marchés sur 35, mais une prévision sans doute trop basse au départ.

LIMITES

Ce que l'étude ne dit pas

Une seule prévision (pop, classement mondial), des données arrêtées fin 2020, année atypique, et des étiquettes de genre parfois trompeuses (le rap classé « indie » en France).

PISTES

Pour aller plus loin

Relancer l'analyse sur d'autres genres et marchés (une ligne à changer), ajouter des données d'**artistes** et de **promotion**, qui expliquent sans doute une grande part du succès.

4

actions pour les labels

Ce que les labels peuvent faire dès maintenant

CALENDRIER

Sortir les nouveautés pop avant décembre

En décembre, les classiques de Noël occupent la place. Une sortie **début novembre** a le temps de s'installer : 84 % des titres pop classés entrent dans le Top 200 dans la semaine de leur sortie.

CHOIX ARTISTIQUES

Raisonner par genre, pas par profil sonore

Le genre explique **27 %** de la popularité, le son moins de 2 %. Chercher un « son à succès » est une fausse piste.

MARCHÉS

Cibler où la pop résiste

Asie du Sud-Est, Nord de l'Europe. Ailleurs, la musique **latine** et le **hip hop** ont pris la tête.

PILOTAGE

Planifier avec la prévision, vérifier chaque semaine

La prévision fixe le calendrier ; un **suivi hebdomadaire** des classements repère à temps un retournement.

MELOWAVE · ÉTUDES MUSICALES

Merci.
Vos questions ?

Les annexes A1 à A7 détaillent les conditions des tests, la taille d'effet, le diagnostic des données, la cadence des sorties, la réutilisation de l'analyse et la lecture des indicateurs d'erreur.

Bader B.
Data Analyst

2 notebooks
Catalogue et prévision

Octobre 2026
Soutenance du projet

ANNEXE A1

3

tests, chacun choisi après vérification de ses conditions

Conditions d'utilisation des tests

Question	Condition vérifiée	Résultat	Test retenu
Energy et loudness sont-elles liées ?	Normalité des deux variables (Shapiro-Wilk)	Rejetée	**Spearman** (Pearson donne 0,76, quasi identique)
La popularité diffère-t-elle selon le genre ?	Normalité **dans chaque genre** (Shapiro-Wilk), règle de décision codée	Rejetée dans tous les genres	**Kruskal-Wallis**, ANOVA (analyse de la variance) en contrôle, test de Dunn pour les paires
Le contenu explicite dépend-il du genre ?	Effectifs attendus suffisants dans le tableau de contingence	Respectée (1 000 morceaux par genre)	**Khi²**, avec le V de Cramér

ANNEXE A2

0,1 %

de la popularité expliquée par danceability, un lien pourtant « très significatif »

Significativité statistique contre taille d'effet

LA P-VALUE

Dit si un effet existe

Avec **113 549 lignes**, le moindre écart devient significatif. Danceability et popularité : r (coefficient de corrélation) = 0,034, et pourtant **p-value = 4×10^{-31}**.

LA TAILLE D'EFFET

Dit si l'effet compte

r = 0,034 explique 0,1 % de la popularité : **négligeable**. C'est la taille d'effet qui guide une décision métier.

Indicateur	Faible	Moyen	Fort	Dans ce projet
r (corrélation)	0,1	0,3	0,5	energy et loudness : **0,75**
ε^2 (epsilon carré, Kruskal-Wallis)	0,01	0,06	0,14	genre : **0,27**
V de Cramér	0,1	0,3	0,5	explicite et genre : **0,40**

ANNEXE A3

5

jours sans donnée exploitable sur 1 405, aucun vrai zéro

Diagnostic des jours à zéro

Cas	Comment le repérer	Jours	Traitement
Trou de collecte	Aucun classement ce jour-là	4 (février à juin 2017)	Valeur manquante
Trou de collecte déguisé	200 lignes vides (titre « N\A », aucun genre) : la règle « classement absent » ne le voit pas	1 (9 juin 2018)	Valeur manquante
Vrai zéro	Classement complet, mais aucun morceau pop	0	Aurait été conservé à 0

Les dates absentes sont d'abord réinsérées dans une grille complète, sinon elles disparaîtraient sans bruit. Prophet gère nativement les valeurs manquantes.

ANNEXE A4

0 jour

délai médian entre la sortie d'un titre pop et son entrée dans le Top 200

Mission 2

Cadence mensuelle des sorties et biais de troncature

PRÉVISION

21 % d'erreur

MAPE (erreur moyenne en pourcentage) 21 %, MAE (erreur absolue moyenne) 47,9 sorties par mois, RMSE (racine de l'erreur quadratique moyenne) 79,5. Quatre mois sur six à 14 sorties près ; l'erreur vient de **juin** (399 prévues, 222 réelles) et **août**.

TRONCATURE

Limitée

84 % des titres classés y entrent dans la semaine, 90 % dans le mois. Seul **octobre 2020** est sous-estimé, d'environ 10 %.

À RETENIR

Décembre, peu de sorties

Décembre compte peu de sorties pop mais le plus de pop classée : le pic de Noël vient des **classiques**, pas des nouveautés.

La série ne compte que les sorties entrées dans les classements, pas toute la production du genre.

ANNEXE A5

9 / 15

artistes du top passeraient le seuil grâce aux doublons

Pourquoi compter chaque morceau une seule fois dans les classements

Artiste	Morceaux comptés (une ligne par genre)	Morceaux réels
Måneskin, 1er du classement sinon	12	5
ROSALÍA	11	5
LISA	10	4
George Ezra	23	8
TWICE (témoin, un genre par titre)	17	17

Règle appliquée : une ligne par couple morceau et genre pour les analyses où le genre est étudié (statistiques, tests) ; une ligne par morceau pour les classements, sinon le seuil de 8 morceaux ne filtre plus rien.

ANNEXE A6

1

ligne à modifier pour relancer l'analyse sur un autre genre ou marché

Réutiliser l'analyse, et usage de l'IA (intelligence artificielle)

RÉUTILISABILITÉ

Un notebook paramétré

GENRE = 'pop' et **MARCHE = 'Global'** en tête du notebook : tout se recalcule, chiffres et graphiques. Graine aléatoire fixée pour des résultats reproductibles.

USAGE DE L'IA

Un assistant, pas un substitut

Aide à la **syntaxe** et à la relecture. Le choix des tests, la lecture des résultats et les conclusions sont vérifiés sur les sorties réelles et assumés à l'oral.

ANNEXE A7

90 jours

mis de côté pour le test, jamais vus par le modèle pendant l'entraînement

Découpage entraînement / test et lecture des indicateurs

Indicateur	Ce qu'il mesure	Pop, chaque jour	Sorties, chaque mois
MAE (erreur absolue moyenne)	L'erreur moyenne, dans l'unité de la série	**18,3** morceaux	**47,9** sorties
RMSE (racine de l'erreur quadratique moyenne)	Pénalise les grosses erreurs : à comparer à la MAE	**19,6**, proche de la MAE : erreur régulière	**79,5**, bien au-dessus : deux grosses erreurs (juin, août)
MAPE (erreur moyenne en pourcentage)	L'erreur relative ; instable si le réel approche de 0	**24,1 %**, fiable : la pop ne descend jamais près de 0	**20,8 %**

DÉCOUPAGE

Le test vient après l'entraînement

Entraînement du 01/01/2017 au 07/08/2020, test du 08/08 au 05/11/2020, ordre vérifié dans le code. Choisir un réglage d'après le test reviendrait à s'en servir pour entraîner.

RÉGLAGE

L'erreur ne vient pas du réglage

Autoriser des ruptures de tendance plus récentes (changepoint_range 0,9 et 0,95) ne fait pas mieux : MAE de 19,2 à 19,4. La reprise commence deux semaines avant la fin de l'entraînement, trop tard pour être vue.